

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«КАЗАНСКИЙ (ПРИВОЛЖСКИЙ) ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»
Институт Вычислительной математики и информационных технологий

Отчет
по обработке естественных языков.
Лабораторный практикум 1

Обучающийся	<u>Генералов Вадим Викторович</u>	<u>гр.09-435</u>	<u> </u>
	(ФИО студента)	(Группа)	(Подпись)

Преподаватель:

Арабов М.К.	<u> </u>
	(Подпись)

Дата сдачи отчета « » 2025 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1. Инструментарий	4
2. Разработка проекта	6
2.1. Парсинг новостных сайтов и приведение текстов к JSONL файлу	6
2.2. Обработка и очистка текстов	6
2.3. Модуль предобработки	7
2.4. Сравнительный анализ методов токенизации и нормализации .	7
2.5. Обучение подсловных моделей токенизации	8
2.6. Разработка веб-приложения для интерактивного анализа	8
2.7. Публикация моделей в Hugging Face Hub	9
ЗАКЛЮЧЕНИЕ	13

ВВЕДЕНИЕ

Лабораторная работа выполнена в рамках предмета «Обработка естественных языков» по программе 2 курса магистратуры.

Целью практики является формирование целостного практического понимания полного цикла обработки текстовых данных в области обработки естественного языка (Natural Language Processing) – от сбора и подготовки неструктурированных текстов до построения и развертывания инференс-моделей. Особое внимание уделить осмысленному сравнению и критическому анализу подходов к одной из ключевых задач NLP — токенизации.

Для достижения данной цели необходимо выполнить следующие задачи:

- освоить методы сбора и предобработки текстовых корпусов, включая извлечение данных из веб-источников;
- реализовать и провести экспериментальное сравнение традиционных и современных методов токенизации, стемминга и лемматизации;
- получить практические навыки обучения подсловных моделей токенизации (BPE, WordPiece, Unigram);
- научиться проводить количественный и качественный анализ эффективности различных алгоритмов с применением объективных метрик;
- разработать и оформить результаты исследования в виде интерактивного веб-интерфейса и API-сервиса;
- освоить процесс публикации обученных моделей и сопроводительной документации в открытых репозиториях.

1. Инструментарий

Для выполнения лабораторной работы использовался современный стек инструментов и библиотек Python, обеспечивающий полный цикл обработки текстовых данных, машинного обучения и визуализации результатов.

Для сбора и обработки текстовых данных использовались:

- requests. Библиотека использовалась для выполнения HTTP-запросов к веб-сайтам новостных агентств. Она обеспечивает получение HTML-кода страниц;
- BeautifulSoup. Основной инструмент для парсинга HTML-документов и извлечения нужных фрагментов текста. Применяется для поиска мета-тегов, выделения содержимого статьи, поиска категорий публикаций, получения всех гиперссылок со страниц;
- urllib.parse (urljoin, urlparse). Применяется для нормализации и объединения относительных и абсолютных URL;
- time. Используется для соблюдения задержек между запросами к одному домену;
- json. Библиотека для сериализации собранных данных в формате JSON Lines (JSONL), где каждая строка – отдельная статья;
- re. Используется для фильтрации неподходящих ссылок, поиска шаблонов дат в тексте HTML, выявления блоков с текстом статьи по ключевым словам в классах;
- dateparser и dateutil.parser. Обе библиотеки применяются для распознавания и нормализации дат публикации из различных форматов. dateparser автоматически определяет дату из строк на естественном языке или из HTML-тегов. dateutil.parser используется как резервный вариант для ISO-форматов.

Для предварительной обработки и очистки текста использовалась библиотека nltk, которая применяется для работы с лингвистическими данными и в данном модуле отвечает за удаление стоп-слов.

Для проектирования универсального модуля предобработки текстов использовалась библиотека html. Она используется для декодирования и замены некоторых html сущностей.

Для сравнительного анализа методов токенизации и нормализации использовались:

- `csv`. Используется для сохранения результатов эксперимента в табличном виде;
- `razdel`. Один из лучших токенизаторов для русского языка, оптимизированный под морфологические особенности;
- `spacy`. Для токенизации, лемматизации;
- `sentence-transformers`. Используется для оценки семантической согласованности текста на основе схожести эмбедингов;
- `sklearn.metrics.pairwise`. Для подсчёта семантической близости между эмбедингами.

На этапе обучения subword моделей токенизации использовались следующие библиотеки:

- `tokenizers` (Hugging Face). Это основная библиотека для работы с подсловными моделями токенизации;
- `pathlib`. Работа с путями к файлам и каталогам в объектно-ориентированном виде;
- `rapidfuzz`. Используется для вычисления нормализованного расстояния Левенштейна между исходным и восстановленным текстом (после токенизации и декодирования). Позволяет оценить качество реконструкции – насколько точно модель токенизатора может восстановить исходную строку;
- `sklearn.metrics.pairwise`. Для подсчёта семантической близости между эмбедингами.

При разработке веб приложения использовались следующие библиотеки:

- `Streamlit`. Создание веб-интерфейса, через который пользователь взаимодействует с системой;
- `Plotly Express`. Используется для отображения гистограмм и бар-чартов в интерфейсе и HTML-отчетах;

2. Разработка проекта

2.1. Парсинг новостных сайтов и приведение текстов к JSONL файлу

Этот модуль автоматически собирает новостные статьи с русскоязычных сайтов.

Он проходит по индексным страницам, собирает ссылки на публика-

ции, парсит каждую статью, очищает её и сохраняет в единый корпус в формате `.jsonl`, где каждая строка – это отдельная статья. Затем мы можем использовать эти данные для дальнейших NLP экспериментов.

Модуль организован модульно и предельно безопасно по отношению к внешним сайтам, имеет задержку и фильтрации.

На рисунке 1 изображена часть файла jsonl, содержащего распарсенные статьи.

1 {"title": "Норик Петров и князь Нахичевский: как снимали сказку со звездами | VГорныч|", "text": "две недели прокат выйдет приключенское фэнтези горныч 📺 4 10 20 30 40 50 60 70 80 90 100 110 120 130 140 150 160 170 180 190 200 210 220 230 240 250 260 270 280 290 300 310 320 330 340 350 360 370 380 390 400 410 420 430 440 450 460 470 480 490 500 510 520 530 540 550 560 570 580 590 600 610 620 630 640 650 660 670 680 690 700 710 720 730 740 750 760 770 780 790 800 810 820 830 840 850 860 870 880 890 900 910 920 930 940 950 960 970 980 990 1000 1010 1020 1030 1040 1050 1060 1070 1080 1090 1100 1110 1120 1130 1140 1150 1160 1170 1180 1190 1200 1210 1220 1230 1240 1250 1260 1270 1280 1290 1300 1310 1320 1330 1340 1350 1360 1370 1380 1390 1400 1410 1420 1430 1440 1450 1460 1470 1480 1490 1500 1510 1520 1530 1540 1550 1560 1570 1580 1590 1600 1610 1620 1630 1640 1650 1660 1670 1680 1690 1700 1710 1720 1730 1740 1750 1760 1770 1780 1790 1800 1810 1820 1830 1840 1850 1860 1870 1880 1890 1900 1910 1920 1930 1940 1950 1960 1970 1980 1990 2000 2010 2020 2030 2040 2050 2060 2070 2080 2090 2100 2110 2120 2130 2140 2150 2160 2170 2180 2190 2200 2210 2220 2230 2240 2250 2260 2270 2280 2290 2300 2310 2320 2330 2340 2350 2360 2370 2380 2390 2400 2410 2420 2430 2440 2450 2460 2470 2480 2490 2500 2510 2520 2530 2540 2550 2560 2570 2580 2590 2600 2610 2620 2630 2640 2650 2660 2670 2680 2690 2700 2710 2720 2730 2740 2750 2760 2770 2780 2790 2800 2810 2820 2830 2840 2850 2860 2870 2880 2890 2900 2910 2920 2930 2940 2950 2960 2970 2980 2990 3000 3010 3020 3030 3040 3050 3060 3070 3080 3090 3100 3110 3120 3130 3140 3150 3160 3170 3180 3190 3200 3210 3220 3230 3240 3250 3260 3270 3280 3290 3300 3310 3320 3330 3340 3350 3360 3370 3380 3390 3400 3410 3420 3430 3440 3450 3460 3470 3480 3490 3500 3510 3520 3530 3540 3550 3560 3570 3580 3590 3600 3610 3620 3630 3640 3650 3660 3670 3680 3690 3700 3710 3720 3730 3740 3750 3760 3770 3780 3790 3800 3810 3820 3830 3840 3850 3860 3870 3880 3890 3900 3910 3920 3930 3940 3950 3960 3970 3980 3990 4000 4010 4020 4030 4040 4050 4060 4070 4080 4090 4100 4110 4120 4130 4140 4150 4160 4170 4180 4190 4200 4210 4220 4230 4240 4250 4260 4270 4280 4290 4300 4310 4320 4330 4340 4350 4360 4370 4380 4390 4400 4410 4420 4430 4440 4450 4460 4470 4480 4490 4500 4510 4520 4530 4540 4550 4560 4570 4580 4590 4600 4610 4620 4630 4640 4650 4660 4670 4680 4690 4700 4710 4720 4730 4740 4750 4760 4770 4780 4790 4800 4810 4820 4830 4840 4850 4860 4870 4880 4890 4900 4910 4920 4930 4940 4950 4960 4970 4980 4990 5000 5010 5020 5030 5040 5050 5060 5070 5080 5090 5100 5110 5120 5130 5140 5150 5160 5170 5180 5190 5200 5210 5220 5230 5240 5250 5260 5270 5280 5290 5300 5310 5320 5330 5340 5350 5360 5370 5380 5390 5400 5410 5420 5430 5440 5450 5460 5470 5480 5490 5500 5510 5520 5530 5540 5550 5560 5570 5580 5590 5600 5610 5620 5630 5640 5650 5660 5670 5680 5690 5700 5710 5720 5730 5740 5750 5760 5770 5780 5790 5800 5810 5820 5830 5840 5850 5860 5870 5880 5890 5900 5910 5920 5930 5940 5950 5960 5970 5980 5990 6000 6010 6020 6030 6040 6050 6060 6070 6080 6090 6100 6110 6120 6130 6140 6150 6160 6170 6180 6190 6200 6210 6220 6230 6240 6250 6260 6270 6280 6290 6300 6310 6320 6330 6340 6350 6360 6370 6380 6390 6400 6410 6420 6430 6440 6450 6460 6470 6480 6490 6500 6510 6520 6530 6540 6550 6560 6570 6580 6590 6600 6610 6620 6630 6640 6650 6660 6670 6680 6690 6700 6710 6720 6730 6740 6750 6760 6770 6780 6790 6800 6810 6820 6830 6840 6850 6860 6870 6880 6890 6900 6910 6920 6930 6940 6950 6960 6970 6980 6990 7000 7010 7020 7030 7040 7050 7060 7070 7080 7090 7100 7110 7120 7130 7140 7150 7160 7170 7180 7190 7200 7210 7220 7230 7240 7250 7260 7270 7280 7290 7300 7310 7320 7330 7340 7350 7360 7370 7380 7390 7400 7410 7420 7430 7440 7450 7460 7470 7480 7490 7500 7510 7520 7530 7540 7550 7560 7570 7580 7590 7600 7610 7620 7630 7640 7650 7660 7670 7680 7690 7700 7710 7720 7730 7740 7750 7760 7770 7780 7790 7800 7810 7820 7830 7840 7850 7860 7870 7880 7890 7900 7910 7920 7930 7940 7950 7960 7970 7980 7990 8000 8010 8020 8030 8040 8050 8060 8070 8080 8090 8100 8110 8120 8130 8140 8150 8160 8170 8180 8190 8200 8210 8220 8230 8240 8250 8260 8270 8280 82

Рисунок 1 – Пример файла corpus.jsonl

2.2. Обработка и очистка текстов

Этот модуль – универсальный препроцессор текстовых данных, который очищает сырой HTML-контент новостных статей и превращает его в стандартизованный, пригодный для NLP-анализов текстов.

Он устраняет шум (HTML-разметку, спецсимволы, URL, дубликаты пробелов и мусорные конструкции), нормализует формат текста (пробелы, регистр) и при необходимости удаляет стоп-слова.

Именно этот модуль используется на предыдущем этапе при формировании корпуса текста, чтобы итоговый `jsonl` содержал текст, очищенный от HTML и имел некоторую предобработку.

2.3. Модуль предобработки

Цель данного модуля – это создать гибкий, конфигурируемый препроцессор, способный приводить тексты к единому формату перед токенизацией и последующим анализом. Основная идея – стандартизировать текст, уstra-

нив вариативность пунктуации, форматирования, чисел, ссылок и сокращений. Это критично для обеспечения стабильности работы токенизаторов и моделей NLP.

В результате работы данного модуля мы получаем следующий артефакт – другой jsonl файл, в который мы сохраняем результат работы данного модуля.

Пример части этого файла изображен на рисунке 2.

```
1 {"title": "Моряк Петров и князь Маковецкий: как снимали сказку со звездами \Горюныч\"", "text": "две недели прокат выйдет приключенческое фэнтези горюныч Анализ. 1  
2 {"title": "Три человека погибли при ударе ВСУ по поселку в Белгородской области", "text": "последствия ракетного удара всу поселку маслова пристань белгородской об  
3 {"title": "Импульс украинскому урегулированию оказался исчерпан, заявил Рябков", "text": "программного обеспечения, пусковых установок ракеты это, скажем так, бола  
4 {"title": "Пенсионный возраст в 2025 – когда выходят на пенсию мужчины и женщины", "text": "список должностей учреждений, работа которых засчитывается стаж работы,  
5 {"title": "Туризм", "text": "пассажиры гости аэропорта смогут увидеть <NUM> крупноформатных снимков, сделанных воздуха. организаторы аэропорт дождевого сервис пуг  
6 {"title": "Популярная ягода оказалась способна улучшать работу мозга", "text": "Ученые Техасского университета а в выяснили, напиток черешни способен улучшать памя  
7 {"title": "Работа в России: права граждан, невыплата зарплаты, исключения", "text": "фото the good brigade getty images россия сотрудник право выходить работу, за  
8 {"title": "Конкурс «Мисс Россия –2025»: кто победил, фото, что известно об Анастасии Венза", "text": "поздно вечером субботу, <NUM> октября, стало известно имя нов  
9 {"title": "Отсутствие реакции США на инициативу России по ДСНВ объяснили", "text": "фото михаил воскресенский риа новости политолог американист рафаэль ордухьян н  
10 {"title": "«У меня сердце ухнуло» Пятидесятичного Максима спасет внутривенное питание. Малышу очень нужна ваша помощь", "text": "максим талерчик москвы родился тяжел  
11 {"title": "В России назвали реальной угрозой поставки США отличных от Tomahawk ракет", "text": "ракета jassm. фото alik keplicz ap настоящей угрозой россия могут п  
12 {"title": "Удары ВСУ поНЗРЗапорожской АЭС: как ответит Россия, какие повреждения нанесли объекту", "text": "фото stringer reuters ответ обстрели вооруженными сила  
13 {"title": "Lenta.ru", "text": "надоело читать события? поиграй нх! собери карту россия фрагментов отечай совети мудрости своей преобразуй жизненные ситуации пон  
14 {"title": "В Москве возле МЖД зарезали мужчину: что произошло, видео с места преступления, комментарии МВД", "text": "фото максим блинов риа новости входа станции  
15 {"title": "Реформы Токаева в Казахстане: суть, причины, последствия для Сената", "text": "фото sputnik gavrill grigorenko pool reuters президент казахстана касым жом  
16 {"title": "Влияние парацетамола на развитие аутизма: мнение биолога", "text": "фото kevin wuht reuters президент соединенные штаты америки дональд трамп брифинге б  
17 {"title": "Экспресс-газета: история, заголовки, суды со звездами, критика, смерть Александра Куприянова", "text": "фото павел бедняков риа новости <NUM> октября с  
18 {"title": "Заявления Трампа о передаче Tomahawk Украине: что сказал, причины, контроль за вооружением, позиция России, мнение политолога", "text": "фото alex wong  
19 {"title": "В Духовном управлении мусульман разъяснили запрет верующим курьерам возить ряд товаров", "text": "фото валентин егорови тасс богословские фетвы решения  
20 {"title": "Сбер запустил депозиты в индийских рупиях. Чем они выгоднее других валют?", "text": "фото francis mascarenhas reuters индийская рупия прочно вошла финан  
21 {"title": "Уральский турбинный завод опроверг сообщения о пожаре", "text": "фото павел лисицын риа новости telegram канал om tv проект внесен министром российская ф  
22 {"title": "Аномальная погода пришла в три региона России", "text": "фото юрий кочетков риа новости аномально теплая погода пришла ненецкий автономный округ ао, нур  
23 {"title": "Арест сотрудниц британской тюрьмы за роман с заключенными: хронология скандала, смарт-тюрьма, преступники", "text": "фото joe giddens ra images getty in  
24 {"title": "Фильм «Шоу ужасов Рокки Хоррора»: рецензия, сюжет, актеры, дата выхода, где смотреть, главные скандалы, запрет", "text": "кадр фильм шоу ужасов рокки хс  
25 {"title": "Синоптик назвал срок наступления заморозков в Москве", "text": "фото агн мос ва заморозки придут москву середине октября. срок наступления жителей столи  
26 {"title": "Неприятный сюрприз поджидал принца Гарри в туалете", "text": "фото paul grover pool reuters стalkerш, преследующую принца гарри всему миру, нашли туале  
27 {"title": "Атака ВСУ на Нововоронежскую АЭС: повреждения, фото, реакция", "text": "фото jose colon anadolul getty images вооруженные силы украины всу ночь вторник,  
28 {"title": "Тайна Бернудского треугольника раскрыта. Почему загадочные исчезновения судов и самолетов так долго не могли объяснить?", "text": "изображение rumi desi  
29 {"title": "ВСУ сталкиваются с дырами на линии боевого соприкосновения: причины, подробности", "text": "фото oleksandr ratushniak reuters вооруженные силы украины в  
30 {"title": "Борьба миллениалов и зумеров: причины, юмор, тренды TikTok", "text": "кадр lutchak1 tiktok <NUM> году свет появились дети нового поколения бета, мемах н  
31 {"title": "Новогодние выходные в 2026 году: отдых продлится 12 дней, перенос выходных, утверждение календаря праздников", "text": "фото sergey eLagin globallookpre  
32 {"title": "В Госдуме напомнили о запрете поднимать арендную плату за жилье чаще раза в год", "text": "фото дмитрий ермаков лента. ру арендная плата жилье повышатс  
33 {"title": "Озвучены потери «Ахмата» во время боев за освобождение Курской области", "text": "фото sergey бобылев риа новости время боев освобождение курской област  
34 {"title": "ФТС передала бойцам СВВ конфискованные машины и технику на 1,63 миллиарда рублей: подробности", "text": "фото станислав красильников риа новости восемь  
35 {"title": "История Ореховской ОПГ: преступления, главарь, расправа, приговор", "text": "кадр сериал лихие лента. ру начинает цикл публикаций, посвященных самим изв  
36 {"title": "Поставки ракет JASSM и LRASM вместо Tomahawk США Украине: вероятность, чем опасны", "text": "фото u. s. air force rachel ross вместо tomahawk соединени  
37 {"title": "Панарамы на Урале: ситуация район, произошедшее шоссе отсюда, позиция России, позиция Венесуэлы" "text": "Анато гуренко palnateks an отсюда панорама мад
```

Рисунок 2 – Пример файла processed.jsonl

2.4. Сравнительный анализ методов токенизации и нормализации

Целью данного этапа является проведение комплексного эмпирического анализа эффективности различных методов токенизации и нормализации текста на русском языке.

Этот шаг завершает блок подготовки данных, позволяя количественно и качественно сравнить, насколько разные комбинации токенизаторов и нормализаторов влияют на размеры словаря, OOV, скорость обработки, сохранение семантического смысла.

В качестве результата работы мы получаем csv файл, в котором наглядно можем увидеть сравнение алгоритмов на разных метриках. Пример вывода данных для моего случая представлен на рисунке 3.

2.5. Обучение подсловных моделей токенизации

Цель этого этапа – эмпирически сравнить эффективность трёх подсловных токенизаторов на едином текстовом корпусе.

	tokenizer ▾	normalizer ▾	vocab_size ▾	oov_pct ▾	time_seconds_per_100_samples ▾	semantic_similarity ▾
1	naive	none	17066	39.5444	0.8458	0.9628
2	naive	porter	17060	39.5079	1.2157	0.9391
3	naive	snowball	9161	20.7214	2.8097	0.6843
4	naive	spacy_lemma	10218	23.0053	29.7590	0.8905
5	regex	none	17062	39.5444	0.8308	0.9417
6	regex	porter	17056	39.5079	1.4422	0.9383
7	regex	snowball	9157	20.7214	2.6184	0.7385
8	regex	spacy_lemma	10213	24.0143	30.2196	0.9007
9	nlTK	none	17081	31.4568	3.9871	0.9855
10	nlTK	porter	17075	31.4277	1.9094	0.9798
11	nlTK	snowball	9176	16.4945	3.6524	0.7688
12	nlTK	spacy_lemma	10148	18.9661	33.4864	0.9268
13	razdel	none	17080	31.4156	0.6414	0.9810
14	razdel	porter	17074	31.3866	1.9242	0.9675
15	razdel	snowball	9175	16.4647	4.4642	0.7880
16	razdel	spacy_lemma	10152	18.9468	35.5236	0.9391
17	spacy	none	17075	31.4342	28.5847	0.9774
18	spacy	porter	17069	31.4052	37.0980	0.9702
19	spacy	snowball	9171	16.4771	32.1862	0.7750
20	spacy	spacy_lemma	10148	18.9603	59.4300	0.9234

Рисунок 3 – Пример файла tokenizationmetrics.csv

Подсловные модели нужны для представления текста на уровне фрагментов слов (токенов), что делает модель более универсальной при обработке редких слов и морфологических форм.

Модуль решает три основные задачи:

- Подготовка корпуса. Чтение из .jsonl, фильтрация, запись в обычный .txt;
- обучение токенизаторов. С помощью библиотеки Hugging Face Tokenizers;
- оценка моделей по метрикам качества реконструкции, фрагментации и сжатия.

В качестве артефактов проекта мы получаем файл trainingresults.csv с метриками по каждой модели, а также 9 обученных токенизаторов (по три на каждую модель с разными параметрами). На рисунках 4 и 5 можно увидеть те самые артефакты проекта после выполнения данного этапа.

mod_ ▾	vocab_ ▾	min_freq_ ▾	model_file ▾	total_lin_ ▾	total_wor_ ▾	total_tok_ ▾	fragmented_ ▾	frag_percent ▾	compression_ ▾	reconstruction_err_ ▾	avg_norm_ ▾
1	bpe	8000	3 output/bpe_v8000_minf3.json	101	56310	102058	30067	53.39548925590481	0.5517450861274962	0.01877625632442802	0.085040930713...
2	bpe	16000	3 output/bpe_v16000_minf3.json	101	56310	94491	26301	46.70751198721364	0.5959297710893101	0.021778908049366946	0.071116856228...
3	bpe	32000	3 output/bpe_v32000_minf3.json	101	56310	94491	26301	46.70751198721364	0.5959297710893101	0.021778908049366946	0.071116856228...
4	wordpiece	8000	3 output/wordpiece_v8000_minf3.json	101	56310	104754	31287	55.56206712839638	0.5375451056761555	0.01873600132467441	0.202017376435...
5	wordpiece	16000	3 output/wordpiece_v16000_minf3.json	101	56310	95322	26497	47.05558515361392	0.590734562850129	0.021227043369585696	0.161731267475...
6	wordpiece	32000	3 output/wordpiece_v32000_minf3.json	101	56310	95322	26497	47.05558515361392	0.590734562850129	0.021227043369585696	0.161731267475...
7	unigram	8000	3 output/unigram_v8000_minf3.json	101	56310	117921	43400	77.07334398863435	0.4775230874907777	0.006305308896481585	0.113936573222...
8	unigram	16000	3 output/unigram_v16000_minf3.json	101	56310	112319	42508	75.48925590481265	0.5013399335820298	0.006455804842689678	0.104751363861...
9	unigram	32000	3 output/unigram_v32000_minf3.json	101	56310	112319	42508	75.48925590481265	0.5013399335820298	0.006455804842689678	0.104751363861...

Рисунок 4 – Пример файла trainingresults.csv

2.6. Разработка веб-приложения для интерактивного анализа

На данном этапе мы разрабатываем интерактивное веб-приложение на streamlit для удобного экспериментирования с методами подсловной токенизации.

Оно превращает исследовательский процесс одного из предыдущих этапов (обучение токенизаторов) в удобный инструмент, где можно:



Рисунок 5 – Пример полученных после обучения токенизаторов артефактов

- загрузить корпус JSONL,
- выбрать тип и параметры токенизатора,
- обучить или применить модель,
- изучить ключевые метрики и распределения,
- экспортировать обученный токенизатор и отчёт.

На рисунке 6 можно увидеть вид веб-приложение и часть его функционала.




Рисунок 6 – Веб-приложение

2.7. Публикация моделей в Hugging Face Hub

Следующим этапом было публикация обученных токенизаторов на Huggingface. Необходимо выбрать лучшую версию каждого из токенизаторов, выложить их и заполнить карточки.

Кроме того необходимо развернуть веб-приложение на Huggingface spacy.

На рисунке 7 представлен профиль с развернутым нами веб-приложением и опубликованными токенизаторами. На рисунках 8, 9, 10 показан оформленный репозиторий с BPE токенизатором. Остальные токенизаторы оформлены схожим образом, поэтому они не будут показаны.




Рисунок 7 – Профиль на HF с опубликованными моделями и веб-приложением




Рисунок 8 – Первая часть с оформлением репозитория BPE токенизатора

 **Корпус**

Токенизатор обучен на корпусе из **55 000+ слов**, собранных с русскоязычных новостных сайтов:

- ria.ru
- lenta.ru
- meduza.io
- kommersant.ru

(Корпус собран в 2025 году и включает тексты новостных статей разных тематик.)

 **Метрики**

Метрика	Значение	Описание
OOV rate	6%	Доля слов, отсутствующих в словаре
Reconstruction accuracy	2%	Точность восстановления исходного текста после токенизации
Compression ratio	0.59	Коэффициент сжатия корпуса

Рисунок 9 – Вторая часть с оформлением репозитория BPE токенизатора

 **Пример использования**

```
from tokenizers import import Tokenizer

tokenizer = Tokenizer.from_pretrained("Shu-vi/russian-bpe-tokenizer-16k")

# Пример
text = "В Казани в 2024 прошёл БРИКС."
encoded = tokenizer.encode(text)

print("Токены:", encoded.tokens)
print("IDs:", encoded.ids)
```

Рисунок 10 – Третья часть с оформлением репозитория BPE токенизатора

ЗАКЛЮЧЕНИЕ

В ходе выполнения проекта были решены все поставленные задачи и на практике изучен весь конвейер NLP от парсинга текстов и до обучения токенизаторов. Работа позволила получить целостное понимание архитектуры NLP-пайплайна и практический опыт взаимодействия с современными библиотеками для задач NLP.

Были разработаны:

- модуль универсальной предобработки текста, обеспечивающий стандартизацию и очистку корпуса,
- три подсловные модели токенизации – BPE, WordPiece и Unigram, обученные на едином корпусе и проанализированные по ряду количественных метрик,
- веб-интерфейс Streamlit для интерактивного сравнения токенизаторов, визуализации распределений и экспорта результатов в HTML и CSV.

Реализованные решения опубликованы в открытом доступе:

- Github-репозиторий проекта: <https://github.com/Shu-vi/NLP>
- BPE токенизатор: https://huggingface.co/Shu-vi/Russian_BPE_Tokenizer_16k
- WordPiece токенизатор: https://huggingface.co/Shu-vi/Russian_wordpiece_tokenizer_32k
- Unigram токенизатор: https://huggingface.co/Shu-vi/Russian_Unigram_Tokenizer_16k
- Веб-приложение: <https://huggingface.co/spaces/Shu-vi/web-app>